SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

OPTIMALIZÁCIA ROZMEROV VSTUPNÝCH SNÍMOK OBLOHY PRE ODHAD SLNEČNÉHO ŽIARENIA

SEMESTRÁLNA PRÁCA

Študijný program:	Multimediálne informačné a komunikačné technológie
Predmet:	I-MKR – Metódy klasifikácie a rozhodovania
Prednášajúci:	doc. Ing. Juraj Kačur, PhD.
Cvičiaci:	doc. Ing. Juraj Kačur, PhD.

Bratislava 2026 **Bc. Lukáš Patrnčiak, Bc. Andrej Tomčík, Bc. Juraj Ševčík**

SÚHRN

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Študijný program:	Multimediálne informačné a komunikačné technológie
Autor:	Bc. Lukáš Patrnčiak, Bc. Andrej Tomčík, Bc. Juraj Ševčík
Semestrálna práca:	Optimalizácia rozmerov vstupných snímok oblohy pre odhad slnečného žiarenia
Vedúci práce:	doc. Ing. Juraj Kačur, PhD.
Miesto a rok predloženia práce:	Bratislava 2026

Táto práca sa zaoberá návrhom a optimalizáciou konvolučných neurónových sietí (CNN) pre odhad intenzity slnečného žiarenia na základe obrazových dát oblohy. Hlavným cieľom je analyzovať vplyv rozmerov vstupných obrázkov na presnosť regresného modelu a identifikovať optimálnu konfiguráciu vstupných dát pre rôzne architektúry vlastných CNN modelov.

V rámci práce boli navrhnuté tri architektúry konvolučných neurónových sietí s rôznou zložitosťou. Pre každú architektúru boli systematicky testované rôzne rozmery vstupných obrázkov spolu s kombináciami hyperparametrov, ako sú rýchlosť učenia, veľkosť spracovanej dávky (batchu), dropout a počet neurónov v plne prepojenej vrstve.

Modely boli trénované a vyhodnocované pomocou metrík strednej absolútnej chyby (MAE), strednej kvadratickej chyby (MSE) a odmocniny zo strednej kvadratickej chyby (RMSE). Súčasne bol analyzovaný čas trénovania a počet potrebných epoch, čím sa zohľadnila aj výpočtová náročnosť jednotlivých konfigurácií.

Výsledky ukazujú, že vhodná voľba rozmeru vstupných obrázkov má významný vplyv na presnosť modelu aj jeho výpočtovú efektívnosť. Na základe experimentov boli identifikované optimálne rozmery vstupov pre jednotlivé architektúry CNN, ktoré dosahujú najnižšiu chybu odhadu slnečného žiarenia.

Kľúčové slová: konvolučné neurónové siete, odhad slnečného žiarenia, snímky oblohy, rozlíšenie obrazu, optimalizácia rozmerov, hlboké učenie, predikcia solárneho žiarenia

Obsah

Úvod **1**

1 Použité metódy **2**

1.1 Konvolučné neurónové siete 2

1.2 Metriky 3

2 Návrh riešenia **5**

2.1 Štruktúra dát 5

2.2 Navrhnuté architektúry 6

2.3 Experimenty 9

3 Implementácia **11**

3.1 predspracovanie dát 12

3.2 Implementcia architektúr CNN 12

3.3 Automatizácia experimentov 13

3.4 Vyhodnotenie modelov 13

3.5 Použitý HW 14

4 Výsledky **15**

4.1 Sledované parametre a metriky 15

4.2 Vplyv hyperparametrov na výsledky 16

4.3 Vyhodnotenie jednotlivých architektúr 16

4.3.1 Small CNN 16

4.3.2 architektura medium 17

4.3.3 Architektura Large 17

4.4 Porovnanie Architektúr 18

4.5 Vplyv zmeny velksoti vstupných obázkov 19

4.6 Najlepší model 20

4.7 Dalšie dobré modely 20

4.8 Diskusia k výsledkom – dat do záveru 21

Záver **22**

Zoznam obrázkov a tabuliek

Obrázok 1 Príklad trénovacieho datasetu 6
Obrázok 2 závyslosť RMSE od velkosti vstupného obrázku 19

Tabuľka 2 Prehľad navrhnutých architektúr CNN 8
Tabuľka 3 Korelácia hyperparametrov a metrík pre všetky architektúry CNN 16
Tabuľka 4 Korelácia hyperparametrov a metrík pre architektúru Small CNN 17
Tabuľka 5 Korelácia hyperparametrov a metrík pre architektúru Medium CNN 17
Tabuľka 6 Korelácia testovacích parametrov a výsledkov v CNN Large . . . 17
Tabuľka 7 Priemerné hodnoty MAE a RMSE pre jednotlivé architektúry CNN 18
Tabuľka 8 Priemerné hodnoty MAE a RMSE pre jednotlivé veľkosti vstupných obrázkov 19
Tabuľka 9 Najlepšie dosiahnuté modely podľa hodnoty testovacej MAE . . 20

Zoznam skratiek

CNN konvolučná neurónová sieť

MAE stredná absolútna chyba

MSE stredná kvadratická chyba

ReLU Rectified Linear Unit

RMSE koreňová stredná kvadratická chyba

Úvod

V tejto práci sa zameriavame na problém odhadu intenzity slnečného žiarenia z fotografií oblohy. Pri návrhu modelov založených na konvolučných neurónových sieťach zohráva významnú úlohu nielen architektúra siete a jej hyperparametre, ale aj vlastnosti vstupných dát. Jedným z kľúčových faktorov je rozmer vstupného obrázka, ktorý ovplyvňuje presnosť modelu a aj výpočtovú náročnosť trénovania.

Cieľom tejto práce je analyzovať vplyv rozmerov vstupných obrázkov na kvalitu regresného modelu a nájsť optimálne nastavenie pre rôzne architektúry konvolučných neurónových sietí. V rámci experimentov sú systematicky testované viaceré konfigurácie modelov a hyperparametrov, pričom výsledky sú vyhodnocované pomocou štandardných chybových metrík a časovej náročnosti trénovania.

Výsledkom práce je identifikácia optimálnych kombinácií architektúry a veľkosti vstupných obrázkov, ktoré poskytujú najlepší kompromis medzi presnosťou odhadu a výpočtovou efektívnosťou, ktorá zohrávala nemalú úlohu pri návrhu celej implementácie vzhľadom na veľkosť datasetu.

1 Použité metódy

V tejto kapitole budú popísané jednotlivé metódy použité v rámci implementácie a vyhodnotenia optimálnych rozmerov obrázkov [**deepLearning**, **globalPooling**, **dropout**, **batchNormalization**].

1.1 Konvolučné neurónové siete

Konvolučné neurónové siete (CNN) predstavujú špecializovaný typ neurónových sietí určený na spracovanie dát s mriežkovou štruktúrou, ako sú napríklad obrázky. Charakteristickou vlastnosťou týchto sietí je využitie operácie konvolúcie, ktorá umožňuje efektívnu extrakciu príznakov zo vstupných dát. Typická architektúra konvolučnej neurónovej siete sa skladá z viacerých základných vrstiev:

- **Vstupná vrstva:** slúži na načítanie vstupných dát, napríklad obrazov definovaného rozmeru. V prípade konvolučných neurónových sietí býva vstup reprezentovaný trojrozmerným tenzorom obsahujúcim výšku, šírku a farebné kanály obrazu.

- **Konvolučné vrstvy:** realizujú extrakciu príznakov zo vstupných dát pomocou konvolučných jadier (filtrov). Príznaky predstavujú charakteristické vlastnosti obrazu, napríklad hrany, textúry, tvary alebo jasové prechody, ktoré neurónová sieť automaticky extrahuje a využíva pri predikcii výslednej hodnoty. Tieto vrstvy umožňujú detekciu hrán, textúr a ďalších charakteristických vlastností obrazu. Počas tréningu sa hodnoty filtrov automaticky optimalizujú tak, aby model dokázal čo najlepšie reprezentovať vstupné dáta.

- **Aktivačné funkcie:** zavádzajú do modelu nelinearitu, vďaka ktorej je možné aproximovať zložité vzťahy medzi vstupmi a výstupmi modelu. Medzi najpoužívanejšie patrí funkcia ReLU (*Rectified Linear Unit*), ktorá nastavuje záporné hodnoty na nulu a kladné hodnoty ponecháva nezmenené. Definícia tejto funkcie vyzerá nasledovne:

$$ReLU(x) = \max(0, x)$$

- **Normalizačné vrstvy:** zabezpečujú normalizáciu aktivácií jednotlivých vrstiev počas tréningu, čím prispievajú k stabilnejšiemu a rýchlejšiemu učeniu modelu. Často sa využíva technika Batch Normalization, ktorá znižuje citlivosť modelu na počiatočné nastavenie parametrov.

- **Pooling vrstvy:** slúžia na redukciu priestorových rozmerov príznakových máp a zníženie výpočtovej náročnosti siete. Najčastejšie sa používa max pooling, pri ktorom sa z vybraného regiónu zachováva iba maximálna hodnota aktivácie.
- **Global pooling vrstvy:** prevádzajú dvojrozmerné príznakové mapy na jednorozmerný vektor pomocou výpočtu globálnych štatistík, napríklad priemeru. Použitie global pooling vrstiev znižuje počet parametrov modelu a tým aj riziko pretrénovania.
- **Plne prepojené vrstvy (Dense):** realizujú kombináciu extrahovaných príznakov a vykonávajú finálne rozhodovanie modelu. Tieto vrstvy sú tvorené klasickými perceptrónmi, pričom každý neurón je prepojený so všetkými neurónmi predchádzajúcej vrstvy. Slúžia na vytváranie vzťahov medzi príznakmi extrahovanými v konvolučných vrstvách a na vytvorenie finálnej predikcie modelu.
- **Regularizačné vrstvy (Dropout):** slúžia na zníženie rizika pretrénovania modelu náhodnou deaktiváciou časti neurónov počas tréningu. Tým sa zabraňuje prílišnému prispôsobeniu modelu trénovacím dátam.
- **Výstupná vrstva:** poskytuje finálny výstup neurónovej siete vo forme klasifikácie alebo numerickej predikcie. Typ aktivačnej funkcie výstupnej vrstvy závisí od charakteru riešenej úlohy.

1.2 Metriky

V tejto kapitole budú popísané metriky, ktoré boli použité na vyhodnotenie úspešnosti navrhnutých modelov konvolučných neurónových sietí. Vzhľadom na to, že cieľom modelu je predikcia spojitej numerickej hodnoty intenzity slnečného žiarenia (*Irradiance*), riešená úloha predstavuje regresný problém. Výstupom modelu teda nie je diskrétna trieda, ako je tomu pri klasifikačných úlohách, ale numerická hodnota reprezentujúca odhadovanú intenzitu žiarenia.

Ako stratová funkcia počas tréningu bola použitá metrika MSE (*Mean Squared Error*), ktorá vyjadruje priemernú kvadratickú chybu medzi skutočnými a predikovanými hodnotami. Ako doplnková metrika počas tréningu bola sledovaná metrika MAE (*Mean Absolute Error*), ktorá predstavuje priemernú absolútnu odchýlku predikcie od skutočnej hodnoty. Na rozdiel od MSE nepriraďuje veľkým chybám výrazne vyššiu váhu, a preto poskytuje jednoduchšiu a ľahšie interpretovateľnú informáciu o priemernej veľkosti chyby modelu.

Po natrénovaní modelu boli výsledky vyhodnotené aj v pôvodnej mierke cieľovej premennej žiarenia (*Irradiance*). Okrem metrík MSE a MAE bola vypočítaná aj metrika RMSE (*Root Mean Squared Error*), ktorá predstavuje druhú odmocninu z hodnoty MSE. Výhodou tejto metriky je, že jej výsledná hodnota sa nachádza v rovnakých jednotkách ako predikovaná veličina *Irradiance*, vďaka čomu je chyba modelu jednoduchšie interpretovateľná z praktického hľadiska.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

$$RMSE = \sqrt{MSE}$$

V uvedených rovniciach označujú jednotlivé symboly:

- n počet vzoriek,
- y_i skutočnú hodnotu cieľovej premennej,
- $\hat{y}_i$ hodnotu predikovanú modelom pre i-tu vzorku.

2 Návrh riešenia

V tejto kapitole bude popísaný návrh riešenia, predovšetkým štruktúra poskytnutých dát, ktoré zahŕňajú tabuľkové (*CSV*) súbory a obrázky oblohy.

2.1 Štruktúra dát

Štruktúra poskytnutých dát vo forme obrázkov použitá v práci je rozdelená na tri základné množiny:

1. **trénovaciu množinu**: slúži na učenie neurónovej siete a aktualizáciu parametrov modelu počas tréningového procesu,
2. **validačnú množinu**: používa sa na priebežné vyhodnocovanie modelu počas tréningu a na výber najvhodnejšej konfigurácie modelu bez priameho učenia,
3. **testovaciu množinu**: slúži na záverečné vyhodnotenie natrénovaného modelu na dátach, ktoré neboli použité počas procesu učenia ani validácie.

Každá časť datasetu je uložená v samostatnom priečinku a obsahuje obrazové dáta spolu so súborom vo formáte CSV, v ktorom sú uložené príslušné hodnoty meranej veličiny. Dataset má nasledujúcu štruktúru:

```
dataset/
|-- train/
|   |-- images/
|   |-- meteo_data.csv
|
|-- val/
|   |-- images/
|   |-- meteo_data.csv
|
|-- test/
|   |-- images/
|   |-- meteo_data.csv
```

Priečinok **images** obsahuje vstupné obrazové dáta vo formáte PNG. Ku každému obrázku je v príslušnom CSV súbore uvedený jeho názov a hodnota cieľovej premennej.

Príklad tadasetu je na 1 kde môžeme vydieť nádoný výber z testovacieho datasetu ktorý sa zobrazuje na začiatku testovania.

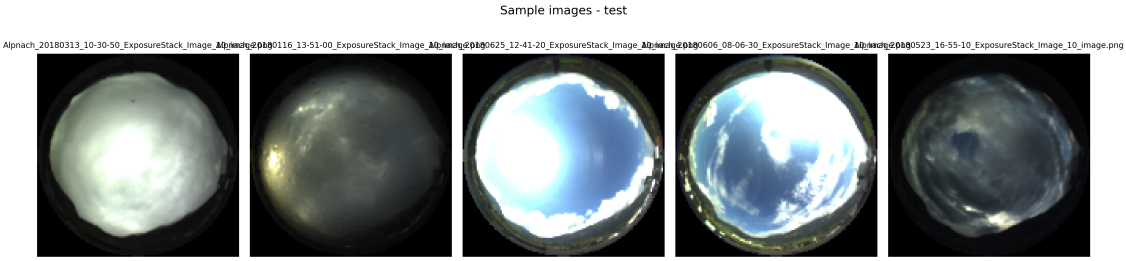

Obrázok 1: Príklad trénovacieho datasetu

V tejto práci boli použité nasledovné stĺpce:

- **PictureName:** obsahuje názov obrazového súboru a slúži na priradenie jednotlivých záznamov k príslušným obrazovým dátam,
- **Irradiance:** obsahuje hodnotu slnečného žiarenia, ktorá predstavuje cieľovú hodnotu predikcie.

Tieto dva stĺpce boli zvolené z dôvodu, že cieľom práce je analyzovať vplyv rozmerov obrazových dát na presnosť predikcie intenzity slnečného žiarenia výhradne na základe obrazových vstupov bez využitia doplnkových meteorologických údajov.

Pri načítaní dát sa ku každému záznamu v CSV súbore priradí úplná cesta k príslušnému obrázku. Záznamy, pri ktorých chýba cieľová hodnota alebo príslušný obrazový súbor, sú z datasetu odstránené. Tým sa zabezpečí, že model pracuje iba s platnými dátami.

Trénovacia množina slúži na učenie modelu, validačná množina sa používa na sledovanie priebehu učenia a výber najlepšej konfigurácie modelu. Testovacia množina je použitá až na záverečné vyhodnotenie natrénovaného modelu na dátach, ktoré neboli použité počas tréningu.

2.2 Navrhnuté architektúry

V rámci práce boli navrhnuté a porovnané tri architektúry konvolučných neurónových sietí, ktoré sa líšia najmä počtom konvolučných vrstiev, počtom filtrov a celkovou zložitosťou modelu. Cieľom návrhu viacerých architektúr bolo overiť, ako vplýva veľkosť a hĺbka neurónovej siete na presnosť predikcie intenzity slnečného žiarenia pri rôznych rozmeroch vstupných obrázkov.

Vstupom do všetkých architektúr boli RGB obrázky oblohy s rozmermi H x W x 3, kde H a W predstavujú výšku a šírku vstupných obrázkov ktorú sme v rámci testovania menili, použili sme velkosti 64x64, 96x96, 128x128, 160x160, 224x224 pixelov.

Navrhnuté architektúry boli označené ako *small*, *medium* a *large*. Všetky modely boli určené na riešenie regresnej úlohy, preto ich výstupná vrstva obsahovala jeden neurón, ktorý reprezentoval predikovanú hodnotu cieľovej premennej *Irradiance*.

- **Small CNN:** predstavuje najjednoduchšiu navrhnutú architektúru. Obsahuje dve konvolučné vrstvy s 16 a 32 filtrami. Po každej konvolučnej časti nasleduje normalizácia dávky a zmenšenie rozmerov pomocou max pooling vrstvy. Táto architektúra bola navrhnutá ako výpočtovo menej náročný model.

- **Medium CNN:** predstavuje stredne zložitú architektúru. Obsahuje tri konvolučné vrstvy s 32, 64 a 128 filtrami. V porovnaní s menšou architektúrou obsahuje viac vrstiev a vyšší počet filtrov, vďaka čomu dokáže extrahovať zložitejšie obrazové príznaky. Súčasťou tejto architektúry sú aj dropout vrstvy, ktoré slúžia na zníženie rizika pretrénovania.

- **Large CNN:** predstavuje najzložitejšiu navrhnutú architektúru. Obsahuje viacero po sebe nasledujúcich konvolučných vrstiev s 32, 64, 128 a 256 filtrami. Táto architektúra umožňuje extrakciu väčšieho množstva príznakov z obrazových dát, avšak zároveň má vyššiu výpočtovú náročnosť.

Prehľad architektúr týchto navrhnutých CNN je možné vidieť v tabuľke 2. Spoločným prvkom všetkých navrhnutých architektúr bolo použitie aktivačnej funkcie ReLU, normalizačných vrstiev Batch Normalization, pooling vrstiev a finálnej vrstvy Global Average Pooling. Hlavnímy výhodou aktovačnej funkcie ReLU, ktorá patrí medzi najčastejšie používanné aktivačné funkcie, je jej jednoduchá implementácia a výpočtová nenárčnosť.

$$ReLU : f(x) = max(0, x)$$

Po extrakcii príznakov nasledovala plne prepojená vrstva, dropout vrstva a výstupná vrstva s jedným neurónom. Všetky navrhnuté architektúry využívajú jednotlivé vrstvy v nasledovnom poradí:

- **Conv2D vrstva:** prvá konvolučná vrstva slúži na extrakciu základných príznakov z obrazových dát, ako sú hrany, textúry alebo jednoduché tvary. Konvolučné filtre sa počas tréningu automaticky prispôsobujú charakteru vstupných dát. Vo všetkých konvolučných vrstvách bola použitá velkosť filtra 3x3.

- **Batch Normalization vrstva:** za konvolučnou vrstvou nasleduje normalizačná vrstva Batch Normalization, ktorá zabezpečuje normalizáciu aktivácií jednotlivých vrstiev počas tréningu. Použitie tejto vrstvy prispieva k stabilnejšiemu a rýchlejšiemu učeniu modelu a znižuje citlivosť na inicializáciu parametrov.

- **Druhá Conv2D vrstva:** druhá konvolučná vrstva umožňuje modelu extrahovať zložitejšie príznaky ešte pred redukciou priestorových rozmerov obrazu. Kombinácia viacerých konvolučných vrstiev za sebou zvyšuje schopnosť modelu zachytiť zložitejšie obrazové charakteristiky.

- **MaxPooling2D vrstva:** pooling vrstva využíva pooling okno s rozmrom 2x2 a slúži na zmenšenie priestorových rozmerov príznakových máp. Tým dochádza k zníženiu výpočtovej náročnosti modelu a zároveň k zachovaniu najvýznamnejších príznakov obrazu.

- **Dropout vrstva:** po pooling vrstve nasledovala regularizačná vrstva Dropout, ktorá počas tréningu náhodne deaktivuje časť neurónov. Cieľom tejto vrstvy je zníženie rizika pretrénovania modelu a zlepšenie generalizačných schopností neurónovej siete.

Takto navrhnutý blok vrstiev bol v architektúrach opakovane použitý s postupne rastúcim počtom konvolučných filtrov. Zvyšovanie počtu filtrov v hlbších vrstvách umožňuje modelu extrahovať zložitejšie a abstraktnejšie príznaky z obrazových dát.

Tabuľka 2: Prehľad navrhnutých architektúr CNN

Architektúra	**Konvolučné filtre**	**Pooling**	**Výstup**
Small CNN	16, 32	MaxPooling, GlobalAveragePooling	1 neurón
Medium CNN	32, 64, 128	MaxPooling, GlobalAveragePooling	1 neurón
Large CNN	32, 32, 64, 64, 128, 128, 256	MaxPooling, GlobalAveragePooling	1 neurón

Pri všetkých architektúrach bola použitá stratová funkcia MSE a optimalizačný algoritmus Adam. Tento algoritmus slúži na postupnú aktualizáciu parametrov neurónovej siete počas tréningu tak, aby sa minimalizovala chyba modelu. Tento algoritmus bol zvolený z dôvodu jeho stabilného a rýchleho učenia, pričom patrí medzi najčastejšie používané optimalizačné algoritmy pri trénovaní konvolučných neurónových sietí. [**adam**].

Počas tréningu bola sledovaná metrika MAE. Na zníženie rizika pretrénovania boli použité vrstvy Dropout a mechanizmus **Early Stopping**, ktorý ukončil tréning v prípade, že sa validačná chyba prestala zlepšovať.

Okrem toho bol použitý mechanizmus **PReduceLROnPlateau**, ktorý automaticky znižoval hodnotu učiaceho koeficientu v prípade, že sa validačná chyba počas viacerých epoch nezlepšovala. Cieľom tohto mechanizmu bolo umožniť modelu jemnejšie dolaďovanie parametrov a stabilnejšiu konvergenciu počas tréningu.

2.3 Experimenty

V rámci experimentálnej časti práce bolo realizované systematické porovnanie navrhnutých architektúr CNN pri rôznych rozmeroch vstupných obrázkov a rôznych nastaveniach hyperparametrov. Cieľom experimentov bolo analyzovať vplyv rozmerov obrazových dát na presnosť predikcie intenzity slnečného žiarenia a zároveň sledovať výpočtovú náročnosť jednotlivých nastavení modelov.

Experimenty boli realizované pre vyššie spomínané architektúry (2.2), pčitom pri experimentoch boli testované nasledovné rozmery vstupných obrázkov:

- 64×64,
- 96×96,
- 128×128,
- 160×160,
- 224×224.

Zvolené rozmery predstavujú často používané veľkosti vstupných obrazových dát pre CNN. Hodnoty boli vybrané tak, aby pokrývali menšie aj väčšie rozlíšenia obrazov a umožnili analyzovať vplyv rastúceho rozmeru vstupných dát na presnosť predikcie a výpočtovú náročnosť modelu. Menšie rozmery, ako napríklad 64×64, umožňujú rýchlejší tréning a nižšie hardvérové nároky, zatiaľ čo väčšie rozmery zachovávajú viac detailov v obraze. Rozmer 224×224 bol zvolený aj z dôvodu, že ide o štandardný vstupný rozmer používaný pri viacerých známych architektúrach CNN.

Maximálny počet tréningových epoch[1] bol nastavený na hodnotu 50. Okrem rozmerov vstupných dát boli experimentálne menené aj vybrané hyperparametre modelov:

- **rýchlosť učenia (learning rate):** táto hodnotaurčuje veľkosť kroku pri aktualizácii parametrov modelu počas tréningu. Vybrané hodnoty predstavujú často používané nastavenia pri trénovaní konvolučných neurónových sietí . Vyššia hodnota 0.001 umožňuje rýchlejšie učenie modelu, zatiaľ čo nižšia hodnota 0.0001 zabezpečuje stabilnejšie a jemnejšie dolaďovanie parametrov. Tieto hodnoty boli nastavené na:

[1]Epocha je plné prejdenie celej trénovacej množiny modelom počas učenia. Tento proces zahŕňa postupné spracovanie všetkých obrázkov, výpočet chyby a aktualizáciu svojich parametrov.

- **dropout:** Nasledovne zvolené hodnoty predstavujú miernu regularizáciu modelu, ktorá umožňuje znížiť riziko pretrénovania bez výrazného obmedzenia schopnosti siete učiť sa z dát. Tieto hodnoty patria medzi často používané nastavenia pri CNN:
  - 0.2 =´20%,
  - 0.3 = 30%,

- **počet neurónov v Dense vrstve:** V práci boli zvolené hodnoty 64 a 128 neurónov s cieľom porovnať, či väčší počet neurónov umožní modelu lepšie zachytiť vzťahy v obrazových dátach a zlepšiť presnosť predikcie.

- **batch size:** Táto hodnota určuje počet vzoriek spracovaných modelom v jednom tréningovom kroku. V práci bola zvolená hodnota 64, ktorá predstavuje kompromis medzi rýchlosťou tréningu, pamäťovou náročnosťou a stabilným priebehom učenia modelu. To znamená, že model počas jedného tréningového kroku spracuje naraz 64 obrazových dát. Napríklad pri trénovacej množine obsahujúcej 25 600 obrázkov je jedna epocha tvorená 400 tréningovými krokmi.

Počas tréningu bol použitý mechanizmus **Early Stopping**, ktorý automaticky ukončil tréning v prípade, že sa presnosť modelu na validačných dátach dlhší čas nezlepšovala. Tým sa zabránilo zbytočne dlhému tréningu a zároveň sa znížilo riziko pretrénovania modelu.

Súčasne bol použitý mechanizmus **ReduceLROnPlateau**, ktorý v prípade, že sa chyba modelu na validačných dátach prestala zlepšovať, automaticky znížil hodnotu učiaceho koeficientu (*learning rate*). Na začiatku tréningu sa model učí rýchlejšie pomocou väčších zmien parametrov, zatiaľ čo po znížení hodnoty learning rate dochádza k jemnejším úpravám modelu. Tento prístup umožňuje presnejšie dolaďovanie parametrov neurónovej siete a pomáha modelu nájsť vhodnejšie riešenie.

Každá konfigurácia modelu bola vyhodnotená pomocou metrík MSE, MAE a RMSE. Výsledky jednotlivých experimentov boli následne porovnané s cieľom identifikovať optimálny rozmer vstupných obrázkov pre jednotlivé architektúry konvolučných neurónových sietí.

3 Implementácia

Na implementáciu navrhnutého riešenia bol použitý programovací jazyk Python [**learningPython**] spolu s viacerými externými knižnicami určenými na spracovanie dát a ich vizualizáciu a tvorbu trénovanie konvolučných neurónových sietí. Implementácia bola realizovaná s rôrazom na jednoduché testovanie a automatizáciu experimentov rôznych konfigurácií a bola navrhnutá tak aby výsledky boli jednoducho replikovatelné. Pri implementácii boli použité nasledovné knižnice:

- **os** – práca so súborovým systémom a adresármi operačného systému,
- **math** – realizácia matematických operácií a výpočtov,
- **time** – meranie času a sledovanie trvania operácií,
- **random** – táto funkcia slúži na generovanie náhodných hodnôt ale pre zachovanie rovnakých podmienok pri trénovaný všetkých modelov a reprodukavetelnosť výsledkov je nastavená premenná RAND_ST na fixnú hodnotu čím sa zebezpečuje že náhodne generované čísla budu pri roznych behoch programu rovnaké.
- **pandas** – spracovanie a analýza tabuľkových dát,
- **numpy** – numerické výpočty a operácie nad viacrozmernými poľami,
- **matplotlib.pyplot** – vizualizácia výsledkov a tvorba grafov,
- **tensorflow** – framework určený na implementáciu a tréning neurónových sietí.

Implementácia sa skladala z viacerých časti ktoré slúžili na načítanie a kontrolu datasetu, predspracovanie vstupných dát, vytvorenie modelu, automatizáciu trénovania a vyhodnotenie výsledkov a generovanei grafov.

Na implementáciu konvolučnej neurónovej siete bolo využité rozhranie Keras, ktoré je súčasťou frameworku TensorFlow. Použitý bol modul **keras.Input** určený na definovanie vstupnej vrstvy neurónovej siete, modul **tensorflow.keras.layers** obsahujúci konvolučné, pooling a plne prepojené vrstvy a modul **tensorflow.keras.models** určený na vytváranie architektúr neurónových sietí.

Na optimalizáciu procesu učenia bol použitý algoritmus **keras.Input**, ktorý sa nachádza v module **tensorflow.keras.optimizers.Adam**. Súčasťou implementácie boli aj callback mechanizmy z modulu **tensorflow.keras.callbacks**, konkrétne:

- **EarlyStopping** – tento mechanizmus slúži na predčasné ukončenie tréningu modelu pri stagnácii validačnej chyby modelu, tento mechanizmus kontroluje zmenu vo validačnej chybe na konci každej trénovacej epochy. Jeho implemmntáciou sa znižuj riziko pretrénovania modelu a skracuje sa čas trénovania.
- **ModelCheckpoint** – toto je mechanizmus implementovaný na automatické uklada-

nie najlepšieho modelu počas tréningu, keď program dokončí trénovanie modelu a je prpravený trénovať ďalší model, tento mechanizmus ho automaticky uloži na zvolené miesto .

- **ReduceLROnPlateau** – táto funkcia zabezpečuje dynamickú úpravu rýchlosti učenia počas tréningu ak vyhodnotí zhoršenie konvergencie modelu.

Pre spracovanie vstupných obrázkov bol použitý modul **tensorflow.keras.preprocessing.image**, konkrétne funkcie:

- **load_img** – načítanie obrazových dát,
- **img_to_array** – prevod obrázkov do numerickej reprezentácie vo forme numerického poľa.

3.1 predspracovanie dát

Pred samotným tréningom modelov bolo potrebé vykonať predspracovania vstupných dát. Na načítanie a úpravu boli implementované funkcie **load_and_preprocess_image()** a **create_tensorflow_dataset()**. Každý vstupný obrázok bol najskôr načítaný z disku a následne transformovaný na požadovaný rozmer podľa aktuálne testovanej konfigurácie modelu. Po zmene rozmerov bol obrázok prevedený na numerické pole typu *NumPy array*. Hodnoty pixelov boli následne normalizované do intervalu $\langle 0, 1 \rangle$ vydelením hodnotou 255:

$$x_{norm} = \frac{x}{255}$$

Táto normalizácia prispieva k stabilnejšiemu priebehu učenia neurónovej siete a znižuje riziko numerických problémov počas optimalizácie modelu.

Okrem vstupných obrazových dát bola normalizovaná aj skúmaná hodnota *Irradiance*. A to pomocov implementovaním štandardizácie priemeru a smerodajnej odchýlky:

$$x_{norm} = \frac{x - \mu}{\sigma}$$

Kde μ je priemernú hodnotu cieľovej premennej a σ je smerodajná odchylka. Táto normalizácia zlepší stabilitu modelov, urýchli proces trénovania a zvýši rýchlosť konvergencie počas trénovania.

Po načítaní a normalizácii boli dáta prevedené do formátu **TensorFlow Dataset**, ktorý umožňuje rozdelovanie dát a používať (*batching*), miešanie dát (*shuffling*) a optimalizáciu načítavanie vstupných dát počas tréningu .

3.2 Implementcia architektúr CNN

Všetky chitektúry boli implementované cez sekvenčný model **tensorflow.keras.Sequential**. Každý model pozostáva z viacerých blokov konvolučných, normalizačných, batch, pooling,

dropout a regulačných vrstiev.

V konvolučnej vrstve sa využívali filtre o veľkosti 3x3 a aktivačná ReLU funkcia. Po každej skupine konvolučných vrstiev nasledovala pooling vrstva typu MaxPooling2D s veľkosťou pooling okna 2x2, ktorá znižuje priestorové rozmery príznakových máp. Na konci konvolučnej časti modelu je GlobalAveragePooling2D vrstva, na prevádzanie dvojrozmerných príznakových máp na jednorozmerný vektor. Táto vrstva tiež znižuje počet parametrov trénovaného modelu v porovnaní s klasickým flatten prístupom a toto tiež pomáha redukovať riziko overfittingu. Za global pooling vrstvou je dense vrstva s nastaviteľným počtom neurónov a následne dropout vrstva. Na výstupe je dense vrstva s jedným neurónom bez aktivačnej funkcie.

3.3 Automatizácia experimentov

Proces trénovanai modelov a ich vyhodnocovania bol v tejto implementácii automatizovaný a to tak že program postupne testoval rôzne kombinácie architektúr, veľkostí vstupných obrázkov a hyperparametrov. Pre každú kombináciu parametrov a architektúry bol automaticky:

- vytvorený tréningový, validačný a testovací dataset,
- inicializovaný model neurónovej siete,
- natrénovaný model na dátach z trénovacieho datastu,
- uložené výsledné metriky aj s informáciamy o parametroch,
- uložený najlepší model,
- vygenerované grafy priebehu učenia a dosiahnutých výsledkov.

Počas tréningu sa zaznamenávali hodnoty tréningovej a validačnej chyby pre každú epochu. Tieto údaje boli následne použité na tvorbu grafov na zobrazenie dosiahnutých výsledkov a procesu trénovia. Výsledky všetkých experimentov sa ukladali do tabulky do výstupného formátu .csv, čo umožnuje ich následné porovnanie a analýzu pomocou korelácií medzi parametrami modelov a dosiahnutými výsledkami.

3.4 Vyhodnotenie modelov

Po dokončení tréningu boli jednotlivé modely vyhodnotené na testovacej množine kde pre každý model boli vypočítané MSE, MAE a RMSE a to v normalizovanej aj pôvodnej hodnote. Tiež bol na vyhodnotenie modelu boli zaznamenávané aj časi tréningu modelu a počet epoch potrebných na konvergenciu pre spusreeným funkcie earlystop a teda môžeme porovnať nielen presnosť rôznich testovaných modelov, ale aj ich výpočtovú náročnosť. Súčasťou implementácie bolo aj automatické generovanie grafov závislosti jednotlivých

hyperparametrov od výsledných metrík. Tieto grafy boli následne použité pri analýze vplyvu rozmerov vstupných obrázkov a hyperparametrov na presnosť modelov.

3.5 Použitý HW

Celý proces trénovania ako už bolo spomenuté je implementovaný v jednom python programe a je navrhnutý ako jeden celok ktorý od spustenia po skončenie nevyžaduje žiadny zásah a na konci automaticky poskytne grafy s dosiahnutími výsledkami. Na spustenie tohoto programu bol použitý software CuDDa (verzia) spôštaná cez WSL2 na GPU a CPU (doplniť čo sa použilo)

4 Výsledky

Proces testovania bol plne automatizovaný. Po dokončení tréningu jednotlivých modelov boli automaticky uložené výsledné metriky, parametre modelov a grafy zobrazujúce priebeh tréningu a vzájomné závislosti medzi sledovanými parametrami. Cieľom experimentálnej časti bolo identifikovať optimálnu kombináciu architektúry CNN, rozmeru vstupných obrázkov a hyperparametrov z hľadiska presnosti predikcie intenzity slnečného žiarenia a zároveň sledovať výpočtovú náročnosť jednotlivých modelov.

4.1 Sledované parametre a metriky

Parametre a metriky ktoré sa o natrénovaných modeloch ukladaly počas trénovania:

- **training_time_seconds** – celkový čas potrebný na natrénovanie modelu v sekundách
- **epochs_trained** – počet epoch na ktorých bol model trénovaný pred aktiváciou mechanizmu EarlyStop
- **train_mae_norm / val_mae_norm / test_mae_norm** – priemerná absolútna chyba v normalizovaných jednotkách
- **train_loss_norm / val_loss_norm / test_loss_norm** – hodnota stratovej funkcie MSE počas tréningu, validácie a testovania
- **val_mse_original / test_mse_original** – priemerná kvadratická chyba v pôvodnej mierke *Irradiance*
- **val_mae_original / test_mae_original** – priemerná absolútna chyba v pôvodnej mierke,
- **val_rmse_original / test_rmse_original** – odmocnina z MSE v pôvodných jednotkách *Irradiance*.

Hlavným cieľom experimentov bolo minimalizovať hodnotu **test_mae_original**, ktorá predstavuje priemernú absolútnu odchýlku predikcie od reálnych hodnôt intenzity slnečného žiarenia. Pri vyhodnocovaní výsledkov sme sledovaly aj rozdiel medzi hodnotami MAE a RMSE. V prípade, že hodnota RMSE výrazne prevyšovala hodnotu MAE, znamenalo to, že model síce vo väčšine prípadov dosahoval dobré výsledky, avšak pri niektorých vzorkách generoval výrazne väčšie chyby predikcie. Súčasne bol sledovaný rozdiel medzi

trénovacou a validačnou stratou. Výrazne nižšia trénovacia chyba pri súčasne vysokej validačnej chybe naznačovala pretrénovanie modelu (*overfitting*).

4.2 Vplyv hyperparametrov na výsledky

Na analýzu vplyvu jednotlivých hyperparametrov na výslednú presnosť modelov a čas tréningu bola použitá korelačná analýza. Skúmaný bol vplyv:

- rozmeru vstupných obrázkov
- hodnoty learning rate
- dropout rate
- počtu neurónov v Dense vrstve

Tabuľka 3 zobrazuje koreláciu medzi sledovanými hyperparametrami a výslednými metrikami naprieč všetkými experimentami.

Tabuľka 3: Korelácia hyperparametrov a metrík pre všetky architektúry CNN

	čas trénovania	epoch trained	MSE	RMSE	MEA
velkosť obrázkov	0,5036	-0,0985	0,3508	0,3519	0,3802
learning rate	0,1644	0,1644	-0,2693	-0,2929	-0,3211
dropout rate	0,0503	0,0573	0,1383	0,1342	0,1420
danse units	0,0637	0,0841	-0,0939	-0,0813	-0,0831

Z tabuľky je možné pozorovať, že najvýraznejší vplyv na čas tréningu mala veľkosť vstupných obrázkov. Rast rozlíšenia vstupných dát zvyšoval výpočtovú náročnosť modelov a zároveň mal negatívny vplyv aj na výsledné hodnoty MSE, RMSE a MAE. Naopak vyššia hodnota *learning rate* mala mierne pozitívny vplyv na výsledné chyby modelov, čo naznačuje, že pri použitých architektúrach bolo učenie s hodnotou 0.001 efektívnejšie ako s hodnotou 0.0001. Dropout rate a počet neurónov v Dense vrstve mali v porovnaní s veľkosťou obrázkov výrazne menší vplyv na výsledné metriky.

4.3 Vyhodnotenie jednotlivých architektúr

4.3.1 Small CNN

Pri architektúre Small CNN bol najvýraznejším faktorom opäť rozmer vstupných obrázkov. So zvyšujúcim sa rozlíšením výrazne rástol čas tréningu modelu, pričom zároveň dochádzalo aj k vemi jemnému zhoršeniu výsledných metrík. Táto architektúra bola najmenej

Tabuľka 4: Korelácia hyperparametrov a metrík pre architektúru Small CNN

SMALL	čas trénovania	epoch trained	MSE	RMSE	MEA
velkosť obrázkov	0,6507	-0,1119	0,0634	0,1884	0,1884
learning rate	0,0977	-0,0344	-0,1501	-0,2491	-0,2491
dropout rate	-0,0525	-0,0306	0,0010	-0,0140	-0,0140
danse units	-0,0518	-0,0229	0,1054	0,0277	0,0277

výpočtovo náročná, avšak v porovnaní so zložitejšími architektúrami dosahovala horšiu presnosť predikcie.

4.3.2 architektura medium

Tabuľka 5: Korelácia hyperparametrov a metrík pre architektúru Medium CNN

MEDIUM	čas trénovania	epoch trained	MSE	RMSE	MEA
velkosť obrázkov	0,8279	0,3614	0,3503	0,3777	0,4307
learning rate	0,1750	0,3246	-0,4008	-0,3976	-0,3800
dropout rate	-0,0910	-0,0710	0,2622	0,2932	0,2937
danse units	-0,0346	-0,0913	-0,1121	-0,1105	-0,0892

Architektúra Medium CNN vykazovala výraznejšiu závislosť medzi veľkosťou obrázkov a výslednými metrikami než architektúra Small CNN. Najlepšie výsledky boli opäť dosahované pri menších rozmeroch vstupných obrázkov. Vplyv learning rate bol pri tejto architektúre výraznejší a vyššia hodnota learning rate prispievala k nižším hodnotám MSE, RMSE aj MAE. Dropout rate mal mierne negatívny vplyv na výslednú presnosť modelu.

4.3.3 Architektura Large

Tabuľka 6: Korelácia testovacích parametrov a výsledkov v CNN Large

LARGE	čas trénovania	epoch trained	MSE	RMSE	MEA
velkosť obrázkov	-0,3020	0,3614	0,5663	0,5513	0,5531
learning rate	0,2041	0,3828	-0,2729	-0,3534	-0,3995
dropout rate	0,1606	0,2167	0,1234	0,1037	0,1411
danse units	0,1705	0,1842	-0,1889	-0,1604	-0,1662

Architektúra Large CNN dosiahla najlepšie výsledky spomedzi všetkých testovaných modelov. Najvýraznejší vplyv na výsledné chyby mala opäť veľkosť vstupných obrázkov.

Zaujímavým výsledkom bola záporná korelácia medzi veľkosťou obrázkov a časom tréningu. Vplyv learning rate bol podobný ako pri architektúre Medium CNN. Vyššia hodnota learning rate umožnila rýchlejšiu a stabilnejšiu konvergenciu modelu.

4.4 Porovnanie Architektúr

Tabuľka 7: Priemerné hodnoty MAE a RMSE pre jednotlivé architektúry CNN

Architektúra	**Priemerné MAE**	**Priemerné RMSE**
Large	86.84	117.49
Medium	106.62	138.38
Small	75.88	103.94

Tabuľka 7 zobrazuje priemerné hodnoty metrík MAE a RMSE pre jednotlivé navrhnuté architektúry konvolučných neurónových sietí. Najlepšie priemerné výsledky dosiahla architektúra Small CNN, ktorá dosiahla priemernú hodnotu MAE 75.88 a RMSE 103.94 a najhoršie výsledky dosiahla architektúra Medium CNN, pri ktorej bola priemerná hodnota MAE 106.62 a RMSE 138.38.

Zaujímavým je že aj ked Large má najlepší model spomedzi priemerné výsledky boli horšie než pri architektúre Small, ktorá ale má druhý najlepší model s podobnímy výsledkami. To naznačuje, že architektúra Large bola citlivejšia na voľbu hyperparametrov a veľkosti vstupných obrázkov. Pri vhodnej konfigurácii dokázala dosiahnuť veľmi dobré výsledky, avšak pri nevhodných nastaveniach dochádzalo k výraznému zhoršeniu presnosti. Naopak architektúra Small má stabilnejšie výsledky pri rôznymi konfiguráciách. Výsledky zároveň ukazujú, že vyššia komplexnosť architektúry automaticky neznamená lepšiu priemernú presnosť modelu.

4.5 Vplyv zmeny velksoti vstupných obázkov

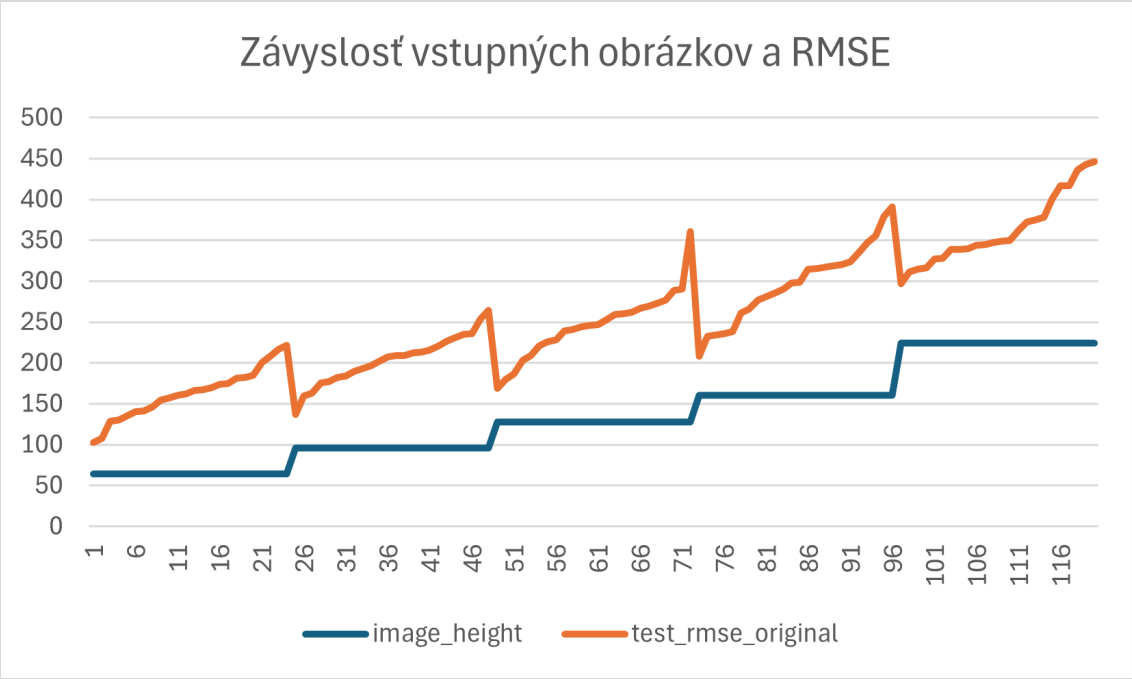

Obrázok 2: závyslosť RMSE od velkosti vstupného obrázku

Tabuľka 8: Priemerné hodnoty MAE a RMSE pre jednotlivé veľkosti vstupných obrázkov

Veľkosť obrázka	Priemerné MAE	Priemerné RMSE
64x64	71.06	99.05
96x96	79.82	107.85
128x128	89.06	117.67
160x160	104.48	136.90
224x224	104.47	138.22

Z grafu na obrázku 2 je možné pozorovať, že so zvyšujúcim sa rozlíšením vstupných obrázkov dochádzalo vo všeobecnosti k rastu hodnoty RMSE. Toto nám potvrdzuje aj tabulka 8 kde vydíme priemerné hodnoty MAE a RMSE pre jednotlivé rozmery vstupných obrázkov naprieč všetkými experimentami a z výsledkov je možné pozorovať postupný rast hodnôt MAE aj RMSE so zvyšujúcim sa rozlíšením vstupných obrázkov. Z tohoto výsledku môžeme usúdiť, že menšie rozmery obrázkov sú vhodnejšie ako väčšie obrázky s väčším rozlíšením. Jedným z možných dôvodov môže byť skutočnosť, že pri väčších rozmeroch vstupných obrázkov sa zvyšuje množstvo detailov a šumu, ktoré nemusia byť

relevantné pre predikciu intenzity slnečného žiarenia. Model tak môže byť náchylnejší na pretrénovanie a zároveň sa výrazne zvyšuje výpočtová náročnosť tréningu. Naopak menšie rozmery obrázkov pravdepodobne zachovali iba najdôležitejšie globálne obrazové charakteristiky oblohy, ktoré boli pre predikciu žiarenia postačujúce.

4.6 Najlepší model

Najlepšie výsledky dosiahol model architektúry **Large CNN** pri nasledovnej konfigurácii:

- veľkosť obrázkov: 64×64
- learning rate: 0.001
- dropout rate: 0.2
- počet neurónov Dense vrstvy: 128
- počet epoch: 42

Celkový čas tréningu tohto modelu bol 203.46 sekundy. Model dosiahol hodnotu:

- test_MAE = 28.3954
- test_RMSE = 39.02075
- test_MSE = 1522.6194

Priemerný čas tréningu všetkých modelov bol 282.0997 sekundy, pričom medián predstavoval 190.6278 sekundy. Priemerná hodnota MAE všetkých modelov (89.7807) bola výrazne vyššia ako výsledok najlepšieho modelu(28.3954), čo potvrdzuje výrazne lepšiu presnosť zvolenej konfigurácie.

4.7 Ďalšie dobré modely

Tabuľka 9: Najlepšie dosiahnuté modely podľa hodnoty testovacej MAE

Arch.	Img size	LR	Dropout	Dense	Epochs	Time [s]	MAE	RMSE
Large	64x64	0.001	0.2	128	42	203.46	28.40	39.02
Small	96x96	0.001	0.2	64	28	118.57	29.60	40.98
Large	128x128	0.001	0.3	64	49	710.94	34.04	40.61
Small	128x128	0.0001	0.2	128	44	222.11	35.36	51.46
Large	64x64	0.001	0.2	64	37	203.64	37.33	43.71
Large	128x128	0.001	0.3	128	50	709.94	40.50	58.19

V tejto časti sa zamerame na 5 modelov s najlepšími výsledkamy hned po najlepšom. Tabuľka 9 zobrazuje najlepšie modely dosiahnuté počas experimentov zoradené podľa hodnoty testovacej metriky MAE. Najlepšie výsledky dosiahla architektúra Large CNN pri veľkosti vstupných obrázkov 64x64, hodnote learning rate 0.001, dropout rate 0.2 a 128 neurónoch v Dense vrstve. Tento model dosiahol hodnotu testovacej MAE 28.40 a RMSE 39.02 pri celkovom čase tréningu približne 203 sekúnd. Z výsledkov je možné pozorovať, že najlepšie modeli používaly menšie rozmery vstupných obrázkov, predovšetkým 64x64 a 96x96. Tento výsledok podporuje predchádzajúce pozorovania, podľa ktorých väčšie rozlíšenia neprinášali zlepšenie presnosti modelov, ale naopak často spôsobovali zhoršenie výsledkov a zvýšenie výpočtovej náročnosti. Zaujímavým výsledkom je aj to, že druhý najlepší model má architektúru Small a rozmery obrázkov 96x96. Táto dosiahla veľmi podobné výsledky ako najlepší model, ale pri výrazne nižšom tréningovom čase čo naznačuje, že jednoduchšie architektúry môžu byť pri vhodne zvolenom rozlíšení a hyperparametroch podobne efektívne ako velké architektúry. Naopak najlepšie modely využívajúce väčšie rozlíšenia vstupných obrázkov, napríklad 128x128, vykazovali vyššie hodnoty MAE aj RMSE a zároveň podstatne dlhší čas tréningu. Pri architektúre Large CNN sa čas tréningu pri rozlíšení 128x128 pohyboval okolo 710 sekúnd, čo je viac ako tri kráť viac času potrebného na vsrupný obrázok 64x64. Výsledky zároveň ukazujú, že hodnota learning rate 0.001 bola pri najlepších modeloch lepšia než hodnota 0.0001 ktorú úpoužíval iba jeden model a väčšina modelov používala drop out rate 0.2.

4.8 Diskusia k výsledkom – dat do záveru

Výsledky experimentov ukázali, že najvýznamnejší vplyv na presnosť všetkých modelov mala veľkosť vstupných obrázkov. Vo väčšine prípadov dosahovali lepšie výsledky modely trénované na menších rozmeroch obrazových dát. Zároveň sa ukázalo, že zložitejšie architektúry CNN dokázali lepšie extrahovať príznaky z obrazových dát a dosahovali nižšie hodnoty chýb. Najlepšie výsledky dosiahla architektúra Large CNN, ktorá obsahovala najväčší počet konvolučných vrstiev a filtrov. Výsledky zároveň naznačujú, že pri riešení úloh predikcie intenzity slnečného žiarenia nemusí byť použitie vysokého rozlíšenia vstupných obrázkov výhodné a maly by byť použité menšie rozmery vstupných dát umožňujú rýchlejší tréning, nižšiu výpočtovú náročnosť a v tomto prípade aj lepšiu presnosť predikcie.

Záver

Cieľom práce bolo analyzovať vplyv rozmerov vstupných obrázkov na presnosť predikcie intenzity slnečného žiarenia pomocou konvolučných neurónových sietí. V rámci práce boli navrhnuté a implementované tri architektúry CNN označené ako Small, Medium a Large, pričom experimenty boli realizované na rôznych veľkostiach vstupných obrazových dát a pri rôznych nastaveniach hyperparametrov.

Výsledky experimentov ukázali, že veľkosť vstupných obrázkov mala najvýraznejší vplyv na presnosť modelov aj na čas tréningu. Vo väčšine experimentov dosahovali lepšie výsledky modely využívajúce menšie rozmery vstupných obrázkov, predovšetkým 64x64 pixelov. So zvyšovaním rozlíšenia nrastala MAE aj RMSE a predlžoval sa času tréningu modelov. Najlepší výsledok dosiahla architektúra **Large CNN** pri veľkosti vstupných obrázkov 64x64, hodnote learning rate 0.001, dropout rate 0.2 a 128 neurónoch v Dense vrstve. Tento model dosiahol hodnotu testovacej MAE 28.40 a RMSE 39.02. Výsledky zároveň ukázali, že vyššia hodnota learning rate 0.001 bola vo väčšine prípadov vhodnejšia ako hodnota 0.0001. Pri porovnaní priemerných výsledkov jednotlivých architektúr dosiahla najlepšie hodnoty architektúra **Small CNN**, ktorá mala stabilnejšie výsledky v rôznymi konfiguráciami a nižšiu výpočtovú náročnosť. Naopak architektúra Large CNN dosahovala veľmi dobré výsledky iba pri vhodne zvolených hyperparametroch a bola citlivejšia na zmenu nastavení. Experimenty zároveň ukázali, že použitie väčších rozlíšení vstupných obrázkov nie je pri predikcii intenzity slnečného žiarenia výhodné. Menšie rozmery pravdepodobne zachovávajú najdôležitejšie charakteristiky, zatiaľ čo väčšie rozlíšenia pridávajú viac detailov a šumu, ktoré zhoršujú schopnosť modelu generalizovať.